TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP

KHOA ĐIỆN TỬ

Bộ môn : Công Nghệ Thông Tin

BÁO CÁO TRÍ TUỆ NHÂN TẠO & HỌC MÁY

ĐỀ TÀI: XÂY DỰNG ỨNG DỤNG PHÁT HIỆN NGƯỜI ĐEO KHẨU TRANG TRONG ẢNH

HỌ VÀ TÊN	**:**	**NGUYỄN ĐỨC DƯƠNG**
LỚP	**:**	**K58KTP.01**
MSSV	**:**	**K225480106093**
GVHD	**:**	**TS. NGUYỄN TUẤN LINH**

Thái Nguyên 2026

TRƯỜNG ĐHKTCN **CỘNG HOÀ XÃ HỘI CHỦ NGHĨA VIỆT NAM**

KHOA ĐIỆN TỬ ***Độc lập - Tự do - Hạnh phúc***

BÀI TẬP LỚN

MÔN HỌC TRÍ TUỆ NHÂN TẠO & HỌC MÁY

BỘ MÔN CÔNG NGHỆ THÔNG TIN

Sinh viên: Nguyễn Đức Dương .....

Lớp: *K58KTP*..... *Ngành: Kỹ thuật Máy Tính*.....

Giáo viên hướng dẫn: TS. Nguyễn Tuấn Linh

Ngày giao đề: 18/12/2025 ..... *Ngày hoàn thành: 01/03/2026* .....

Tên đề tài : Xây dựng ứng dụng phát hiện người đeo khẩu trang trong ảnh .....

Yêu cầu :

Mô tả bài toán :

- Bài toán đặt ra là xây dựng một mô hình trí tuệ nhân tạo có khả năng phát hiện vị trí của những người đang đeo khẩu trang trong ảnh đầu vào. Cụ thể, hệ thống nhận dữ liệu đầu vào là ảnh hoặc khung hình video, sau đó sử dụng thuật toán phát hiện đối tượng như YOLOv8 để xác định các vùng chứa người đeo khẩu trang và hiển thị kết quả bằng khung viền cùng nhãn nhận dạng. Hệ thống cần đảm bảo tốc độ xử lý nhanh, độ chính xác cao và hoạt động tốt trong các điều kiện khác nhau như ánh sáng yếu, góc chụp đa dạng, khoảng cách xa hoặc môi trường phức tạp.....

.....

Mô tả dữ liệu:

- Thứ nhất, tập ảnh có sự đa dạng về điều kiện ánh sáng, góc chụp, khoảng cách và môi trường. Ví dụ: ảnh trong nhà, ngoài trời, nơi đông người hoặc khu vực công cộng. Điều này giúp mô hình học được nhiều đặc trưng khác nhau, giảm hiện tượng nhận diện sai trong thực tế.

- Thứ hai, dữ liệu được gán nhãn theo dạng phát hiện đối tượng. Mỗi ảnh chứa các thông tin về vị trí của người đeo khẩu trang thông qua các khung bao (bounding box) và nhãn tương ứng. Việc gán nhãn này được thực hiện theo định dạng phù hợp với mô hình YOLOv8, trong đó mỗi đối tượng được xác định bởi tọa độ và lớp phân loại.

- Thứ ba, dữ liệu được chia thành các tập chính gồm:

- *Tập huấn luyện (Training set): chiếm phần lớn dữ liệu, dùng để đào tạo mô hình.*
- *Tập kiểm tra (Validation set): dùng để điều chỉnh tham số và đánh giá trong quá trình huấn luyện.*
- *Tập thử nghiệm (Test set): dùng để đánh giá hiệu năng cuối cùng của hệ thống.*

Mô hình học máy:

- Trong đề tài này, mô hình được sử dụng là mô hình học sâu (Deep Learning) thuộc nhóm phát hiện đối tượng (Object Detection). Cụ thể, hệ thống áp dụng kiến trúc YOLOv8 – một phiên bản cải tiến trong họ YOLO (You Only Look Once), nổi bật với khả năng phát hiện đối tượng theo thời gian thực với độ chính xác cao và tốc độ xử lý nhanh.

- YOLOv8 hoạt động theo cơ chế chia ảnh đầu vào thành các vùng lưới (grid) và dự đoán trực tiếp các bounding box cùng xác suất lớp đối tượng chỉ trong một lần lan truyền (forward pass) qua mạng nơ-ron. Điều này giúp mô hình đạt hiệu suất cao hơn so với các phương pháp hai giai đoạn (two-stage detectors) như R-CNN.Giao diện:

Giao diện:

- Giao diện của hệ thống phát hiện người đeo khẩu trang được thiết kế đơn giản, thân thiện với người dùng, giúp dễ dàng thao tác và kiểm tra kết quả nhận dạng. Hệ thống có thể được xây dựng dưới dạng website, cho phép người dùng tải ảnh lên và nhận kết quả phát hiện trực tiếp trên trình duyệt.

GIÁO VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

NHẬN XÉT CỦA GIÁO VIÊN

.....
.....
.....
.....
.....
.....

Thái Nguyên, Ngày… Tháng… Năm 2026

GIÁO VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

MỤC LỤC

DANH MỤC BẢNG VÀ HÌNH ẢNH 6
LỜI MỞ ĐẦU 7
CHƯƠNG I: TỔNG QUAN 8
1.1. Đặt vấn đề 8
1.1.1. Mô tả bài toán 8
1.1.2. Dữ liệu đầu vào - Đầu ra 8
1.2. Lý do chọn đề tài 9
1.3. Mục tiêu đề tài 10
1.4. Đóng góp của báo cáo 10
CHƯƠNG II: CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN 12
2.1. Các nghiên cứu liên quan 12
2.1.1. Hướng tiếp cận truyền thống 12
2.1.2. Hướng tiếp cận Deep Learning 13
2.2. Cơ sở lý thuyết 14
2.2.1. Tổng quan về CNN 14
2.2.2. Lớp tích chập - Convolution Layer 16
2.2.3. Hàm kích hoạt ReLU 17
2.2.4. Tầng Pooling 17
2.2.5. Flatten và Fully Connected 18
2.2.6. Hàm Softmax và phân loại 18
2.2.7. Hàm mất mát (Loss Function) 18
2.2.8. Lan truyền ngược (Backpropagation) 19
CHƯƠNG III: PHƯƠNG PHÁP THỰC HIỆN 20
3.1. Mô tả dữ liệu 20
3.1.1. Tập dữ liệu 20
3.1.2. Phương pháp đánh giá 21
3.2. Khám phá và Tiền xử lý dữ liệu 22
3.2.1. Khám phá dữ liệu 22
3.2.2. Làm sạch dữ liệu 23
3.2.3. Lợi ích của làm sạch dữ liệu 26

3.3. Mô hình đề xuất 26
3.3.1. Tổng quan kiến trúc 26
3.3.2. Sơ đồ khối của hệ thống 28
3.3.3. Hàm mất mát và thuật toán tối ưu 30
CHƯƠNG IV: THỰC NGHIỆM VÀ KẾT QUẢ 35
4.1. Môi trường thực nghiệm 35
4.1.1. Cấu hình phần cứng 35
4.1.2. Thư viện và công cụ sử dụng 35
4.2. Các siêu tham số 36
4.3. Tiêu chí đánh giá 36
4.4. Kết quả thực nghiệm 38
4.4.1. Bảng so sánh kết quả trên các tập dữ liệu 38
4.4.2. Biểu đồ Learning Curve 39
4.4.3. Biểu đồ Confusion Matrix 39
CHƯƠNG V: THẢO LUẬN VÀ PHÂN TÍCH LỖI 40
5.1. Phân tích kết quả 40
5.2. Phân tích lỗi 41
5.3. Hạn chế 43
CHƯƠNG VI: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 44
6.1. Kết luận 44
6.2. Hướng phát triển 45
TÀI LIỆU THAM KHẢO 46
PHỤ LỤC 47

DANH MỤC BẢNG VÀ HÌNH ẢNH

Hình 2.1. Sơ đồ hướng tiếp cận truyền thống 12
Hình 2.2. Sơ đồ deep learning phân hiện khuôn mặt và phân loại 13
Hình 2.3. Sơ đồ deep learing (End - to - End) 14
Hình 2.4. Ví dụ mảng ma trận RGB 6x6x3 (3 ở đây là giá trị RGB) 15
Hình 2.5. Sơ đồ kiến trúc tổng quát của CNN trong bài toán 15
Bảng 3.1. Bảng bộ dữ liệu Face Mask 20
Hình 3.1. Trích xuất từ bộ dữ liệu mẫu đeo khẩu trang và không đeo khẩu trang . 20
Hình 3.2. Biểu đồ phân lớp 22
Hình 3.3. Biểu đồ phân bố kích thước đối tượng 23
Hình 3.2. Sơ đồ kiến trúc tổng quát 26
Hình 3.3. Sơ đố khối hệ thống 28
Hình 3.4. Sơ đồ Binary Cross Entropy Loss 31
Hình 3.5. Sơ đồ Localization Loss 32
Hình 3.6. Sơ đồ Objectness Loss 33
Hình 3.7. Sơ đồ Gradient Descent 34
Bảng 4.1. Bảng các siêu tham số 36
Bảng 4.2. Bảng so sánh kết quả trên các tập dữ liệu 38
Hình 4.1. Biểu đồ Learning Curve 39
Hình 4.2. Biểu đồ Confusion Matrix 39
Hình 5.1. Ảnh gốc 40
Hình 5.2. Ảnh đã phát hiện 40
Hình 5.3. Lỗi thứ nhất còn chưa hoàn thiện trên hệ thống 41
Hình 5.4. Lỗi thứ 2 trên hệ thống 42

LỜI MỞ ĐẦU

Trong những năm gần đây, sự phát triển mạnh mẽ của trí tuệ nhân tạo và học sâu đã mở ra nhiều ứng dụng quan trọng trong lĩnh vực thị giác máy tính. Các hệ thống nhận diện và phát hiện đối tượng ngày càng được áp dụng rộng rãi trong giám sát an ninh, y tế, giao thông và quản lý công cộng. Đặc biệt, sau giai đoạn dịch bệnh, việc đeo khẩu trang tại nơi đông người trở thành một trong những biện pháp quan trọng nhằm bảo vệ sức khỏe cộng đồng.

Tuy nhiên, việc giám sát thủ công tình trạng đeo khẩu trang tại các khu vực công cộng như trường học, bệnh viện, trung tâm thương mại hay cơ quan làm việc gặp nhiều khó khăn do số lượng người lớn và yêu cầu theo dõi liên tục. Xuất phát từ thực tế đó, đề tài "Phát hiện người đeo khẩu trang trong ảnh" được thực hiện với mục tiêu xây dựng một hệ thống tự động có khả năng phát hiện và xác định vị trí người đang đeo khẩu trang thông qua công nghệ học sâu.

Trong đề tài này, mô hình phát hiện đối tượng YOLOv8 được sử dụng để huấn luyện và triển khai hệ thống, nhằm đảm bảo tốc độ xử lý nhanh và độ chính xác cao. Hệ thống có thể tích hợp với nền tảng web hoặc API thông qua FastAPI, cho phép ứng dụng trong các hệ thống giám sát thực tế.

Đề tài không chỉ mang ý nghĩa thực tiễn trong việc hỗ trợ đảm bảo an toàn sức khỏe cộng đồng mà còn góp phần giúp người thực hiện củng cố kiến thức về học sâu, xử lý ảnh và triển khai mô hình trí tuệ nhân tạo vào ứng dụng thực tế.

CHƯƠNG I: TỔNG QUAN

1.1. Đặt vấn đề

1.1.1. Mô tả bài toán

Trong bối cảnh các bệnh truyền nhiễm lây qua đường hô hấp ngày càng phổ biến, việc đeo khẩu trang tại các khu vực công cộng đóng vai trò quan trọng trong việc bảo vệ sức khỏe cộng đồng. Tuy nhiên, việc kiểm soát và giám sát tình trạng đeo khẩu trang tại các địa điểm đông người như trường học, bệnh viện, trung tâm thương mại hay cơ quan làm việc vẫn chủ yếu được thực hiện thủ công, gây tốn thời gian, nhân lực và dễ xảy ra sai sót.

Do đó, bài toán đặt ra là xây dựng một hệ thống tự động có khả năng phát hiện người đeo khẩu trang trong ảnh hoặc video dựa trên công nghệ trí tuệ nhân tạo và thị giác máy tính. Hệ thống cần đảm bảo tốc độ xử lý nhanh, độ chính xác cao và có khả năng hoạt động trong nhiều điều kiện môi trường khác nhau.

1.1.2. Dữ liệu đầu vào - Đầu ra

- Input: Một ảnh tĩnh (image) chứa một hoặc nhiều người trong các môi trường khác nhau.
- Output: Ảnh kết quả hiển thị vị trí những người đeo khẩu trang thông qua các khung bao (bounding box) kèm theo nhãn phân loại tương ứng.

Hệ thống sử dụng mô hình phát hiện đối tượng dựa trên kiến trúc ***YOLOv8***, cho phép xác định vị trí và phân loại đối tượng trong ảnh chỉ trong một lần xử lý, đảm bảo tốc độ nhanh và độ chính xác cao.

Bài toán này thuộc nhóm bài toán ***Object Detection***, trong đó hệ thống không chỉ phân loại xem trong ảnh có người đeo khẩu trang hay không, mà còn phải xác định chính xác vị trí của đối tượng đó trong không gian ảnh.

1.2. Lý do chọn đề tài

Bài toán phát hiện người đeo khẩu trang trong ảnh có ý nghĩa quan trọng trong bối cảnh xã hội hiện nay, đặc biệt khi các bệnh truyền nhiễm qua đường hô hấp có nguy cơ bùng phát và lây lan nhanh trong cộng đồng. Việc đeo khẩu trang là một trong những biện pháp phòng ngừa hiệu quả giúp giảm nguy cơ lây nhiễm, bảo vệ sức khỏe cá nhân và cộng đồng.

Tuy nhiên, việc giám sát thủ công tại các khu vực đông người như trường học, bệnh viện, trung tâm thương mại hoặc cơ quan làm việc gặp nhiều khó khăn do số lượng người lớn và yêu cầu theo dõi liên tục. Điều này dẫn đến nguy cơ bỏ sót hoặc không kiểm soát được toàn diện. Vì vậy, việc xây dựng một hệ thống tự động sử dụng trí tuệ nhân tạo để phát hiện người đeo khẩu trang giúp nâng cao hiệu quả giám sát và giảm sự phụ thuộc vào con người.

Ngoài ra, bài toán này còn góp phần thúc đẩy việc ứng dụng các công nghệ học sâu hiện đại như ***YOLOv8*** trong các hệ thống giám sát thông minh, từ đó nâng cao chất lượng quản lý và an ninh trong xã hội.

Đề tài mang lại nhiều giá trị ứng dụng trong thực tế, cụ thể như:

- Hỗ trợ giám sát tự động tại các khu vực công cộng như bệnh viện, trường học, sân bay, trung tâm thương mại.
- Giảm chi phí nhân lực và nâng cao hiệu quả quản lý so với phương pháp giám sát truyền thống.
- Cung cấp dữ liệu thống kê nhanh chóng về mức độ tuân thủ đeo khẩu trang, hỗ trợ công tác quản lý và ra quyết định.
- Có thể tích hợp vào hệ thống camera giám sát hoặc nền tảng web thông qua FastAPI, giúp triển khai linh hoạt trong nhiều môi trường khác nhau.

1.3. Mục tiêu đề tài

Mục tiêu chính của đề tài là xây dựng một hệ thống phát hiện người đeo khẩu trang trong ảnh dựa trên công nghệ học sâu, đảm bảo tính chính xác, ổn định và có khả năng ứng dụng thực tế.

Các mục tiêu cụ thể cần đạt được bao gồm:

- Xây dựng và chuẩn hóa bộ dữ liệu ảnh chứa người đeo khẩu trang phục vụ cho quá trình huấn luyện và đánh giá mô hình.
- Tiền xử lý và gán nhãn dữ liệu theo định dạng phù hợp với mô hình phát hiện đối tượng.
- Huấn luyện mô hình phát hiện dựa trên kiến trúc YOLOv8 nhằm nhận diện và xác định vị trí người đeo khẩu trang trong ảnh.
- Tối ưu tham số huấn luyện (epochs, learning rate, batch size…) để nâng cao hiệu suất mô hình.
- Đạt độ chính xác phát hiện (mAP) từ 80% trở lên trên tập dữ liệu kiểm thử.
- Xây dựng hệ thống cho phép người dùng tải ảnh đầu vào và hiển thị kết quả phát hiện một cách trực quan.
- Đánh giá hiệu năng hệ thống dựa trên các chỉ số như Precision, Recall và mAP, đồng thời phân tích ưu điểm và hạn chế của mô hình.

Thông qua các mục tiêu trên, đề tài hướng đến việc xây dựng một giải pháp phát hiện người đeo khẩu trang trong ảnh có độ tin cậy cao, sẵn sàng cho việc mở rộng và triển khai trong môi trường thực tế.

1.4. Đóng góp của báo cáo

Trong khuôn khổ đề tài, báo cáo đã thực hiện các nội dung chính sau:

- Nghiên cứu tổng quan về bài toán phát hiện đối tượng trong lĩnh vực thị giác máy tính và các phương pháp học sâu hiện đại.
- Thu thập, xây dựng và tiền xử lý bộ dữ liệu ảnh phục vụ cho việc huấn luyện mô hình phát hiện người đeo khẩu trang.
- Thực hiện gán nhãn dữ liệu theo định dạng phù hợp với mô hình YOLOv8.

- Huấn luyện và tối ưu mô hình nhằm nâng cao độ chính xác và khả năng tổng quát hóa trên các dữ liệu thực tế.
- Xây dựng hệ thống ứng dụng cho phép người dùng tải ảnh đầu vào và nhận kết quả phát hiện trực quan.
- Tích hợp mô hình với nền tảng web thông qua FastAPI để phục vụ triển khai thực tế.

Kết quả của đề tài cho thấy hệ thống có khả năng phát hiện người đeo khẩu trang trong ảnh với độ chính xác cao và thời gian xử lý nhanh, góp phần chứng minh tính khả thi của việc ứng dụng trí tuệ nhân tạo trong các hệ thống giám sát thông minh.

CHƯƠNG II: CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN

2.1. Các nghiên cứu liên quan

2.1.1. Hướng tiếp cận truyền thống

Tập trung vào các đặc trưng hình học và kết cấu được thiết kế thủ công ***(Hand-crafted features)***. Tiêu biểu là thuật toán ***Viola-Jones (2001)*** sử dụng Haar Cascade để phát hiện khuôn mặt với tốc độ xử lý thời gian thực. Sau đó, ***LBP (Local Binary Patterns)*** và ***HOG (Histogram of Oriented Gradients)*** trở thành tiêu chuẩn để mô tả đặc trưng nhờ tính ổn định với ánh sáng.

Trước khi Deep Learning phát triển mạnh, bài toán phát hiện khẩu trang thường được giải quyết theo quy trình hai bước:

Hình 2.1. Sơ đồ hướng tiếp cận truyền thống

Hạn chế:

- Phụ thuộc mạnh vào đặc trưng thủ công (handcrafted features)
- Độ chính xác giảm trong điều kiện ánh sáng phức tạp
- Khó mở rộng khi dữ liệu lớn

2.1.2. Hướng tiếp cận Deep Learning

Sự bùng nổ của mạng nơ-ron tích chập ***(CNN)***. Các mô hình như ***DeepFace (Facebook***) hay ***FaceNet (Google)*** đã phá vỡ giới hạn về độ chính xác bằng cách học các vector đặc trưng (embeddings) trong không gian Euclid, giúp thu hẹp khoảng cách giữa nhận diện máy và mắt người.

a) Cách 1: Phát hiện khuôn mặt → Phân loại khẩu trang

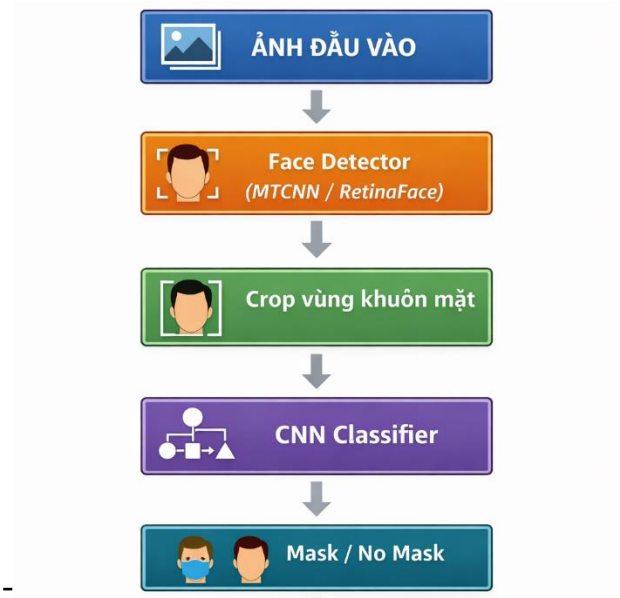

Hình 2.2. Sơ đồ deep learning phân hiện khuôn mặt và phân loại

Cách này chia bài toán thành 2 bước

- Bước 1: Xác định vị trí khuôn mặt
- Bước 2: Phân loại trạng thái đeo khẩu trang

Ưu điểm: chính xác cao

Nhược điểm: xử lý chậm hơn do 2 giai đoạn

b) Cách 2: Object Detection (End-to-End)

Sử dụng các mô hình phát hiện vật thể như:

- YOLO
- SSD
- Faster R-CNN

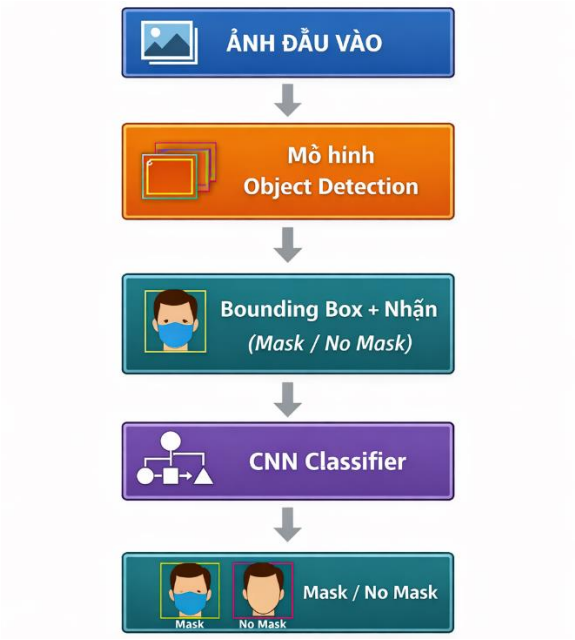

Hình 2.3. Sơ đồ deep learing (End - to - End)

Mô hình vừa xác định vị trí khuôn mặt vừa phân loại trong một lần suy luận.

Ưu điểm: nhanh, phù hợp thời gian thực

Nhược điểm: yêu cầu dữ liệu lớn và tài nguyên tính toán cao

2.2. Cơ sở lý thuyết

2.2.1. Tổng quan về CNN

Trong mạng neural, mô hình mạng neural tích chập (CNN) là 1 trong những mô hình để nhận dạng và phân loại hình ảnh. Trong đó, xác định đối tượng và nhận dạng khuôn mặt là 1 trong số những lĩnh vực mà CNN được sử dụng rộng rãi.

CNN phân loại hình ảnh bằng cách lấy 1 hình ảnh đầu vào, xử lý và phân loại nó theo các hạng mục nhất định (Ví dụ: Chó, Mèo, Hổ, ...). Máy tính coi hình ảnh đầu vào là 1 mảng pixel và nó phụ thuộc vào độ phân giải của hình ảnh. Dựa trên độ phân giải hình ảnh, máy tính sẽ thấy H x W x D (H: Chiều cao, W: Chiều rộng, D: Độ dày).

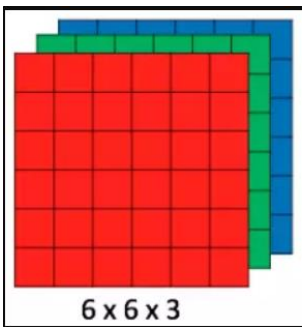

Hình 2.4. Ví dụ mảng ma trận RGB 6x6x3 (3 ở đây là giá trị RGB)

Về kỹ thuật, mô hình CNN để training và kiểm tra, mỗi hình ảnh đầu vào sẽ chuyển nó qua 1 loạt các lớp tích chập với các bộ lọc (Kernals), tổng hợp lại các lớp được kết nối đầy đủ (Full Connected) và áp dụng hàm Softmax để phân loại đối tượng có giá trị xác suất giữa 0 và 1. Hình dưới đây là toàn bộ luồng CNN để xử lý hình ảnh đầu vào và phân loại các đối tượng dựa trên giá trị.

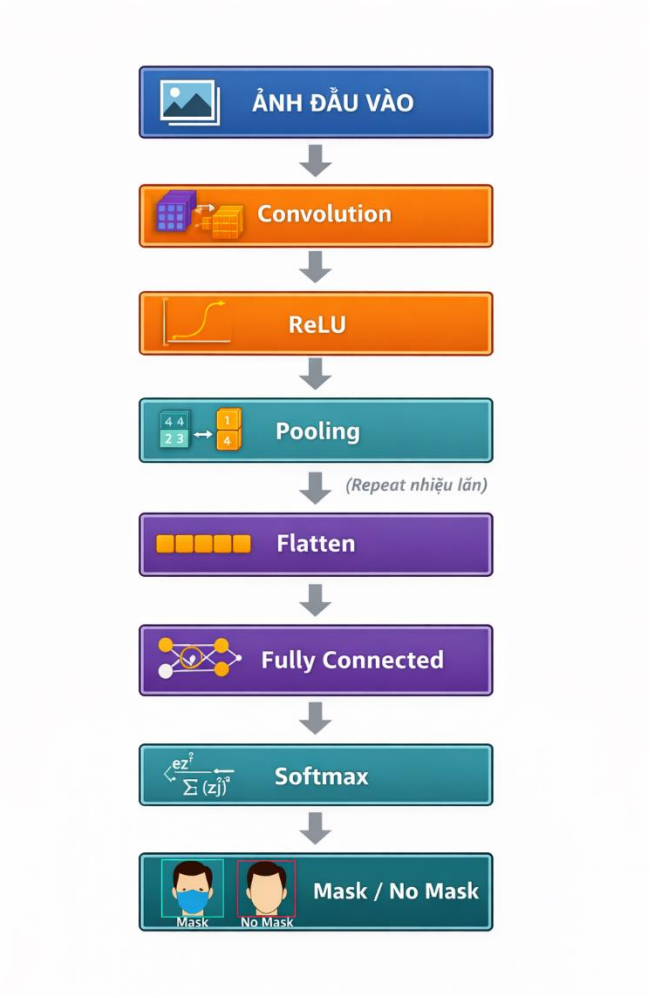

Hình 2.5. Sơ đồ kiến trúc tổng quát của CNN trong bài toán

2.2.2. Lớp tích chập - Convolution Layer

Tích chập là lớp đầu tiên để trích xuất các tính năng từ hình ảnh đầu vào. Tích chập duy trì mối quan hệ giữa các pixel bằng cách tìm hiểu các tính năng hình ảnh bằng cách sử dụng các ô vương nhỏ của dữ liệu đầu vào. Nó là 1 phép toán có 2 đầu vào như ma trận hình ảnh và 1 bộ lọc hoặc hạt nhân.

Lớp này là phần quan trọng nhất của toàn mạng CNN, nó có nhiệm vụ thực thi các tính toán. Các yếu tố quan trọng trong lớp Convolutional là: padding, stride, feature map và filter map.

- Sử dụng filter để áp dụng vào các vùng của ma trận hình ảnh. Các filter map là các ma trận 3 chiều, bên trong đó là những tham số và chúng được gọi là parameters.
- Stride tức là bạn dịch chuyển filter map theo từng pixel dựa vào các giá trị từ trái qua phải.
- Padding: Thường, giá trị viền xung quanh của ma trận hình ảnh sẽ được gán các giá trị 0 để có thể tiến hành nhân tích chập mà không làm giảm kích thước ma trận ảnh ban đầu.
- Feature map: Biểu diễn kết quả sau mỗi lần feature map quét qua ma trận ảnh đầu vào. Sau mỗi lần quét thì lớp Convolutional sẽ tiến hành tính toán.

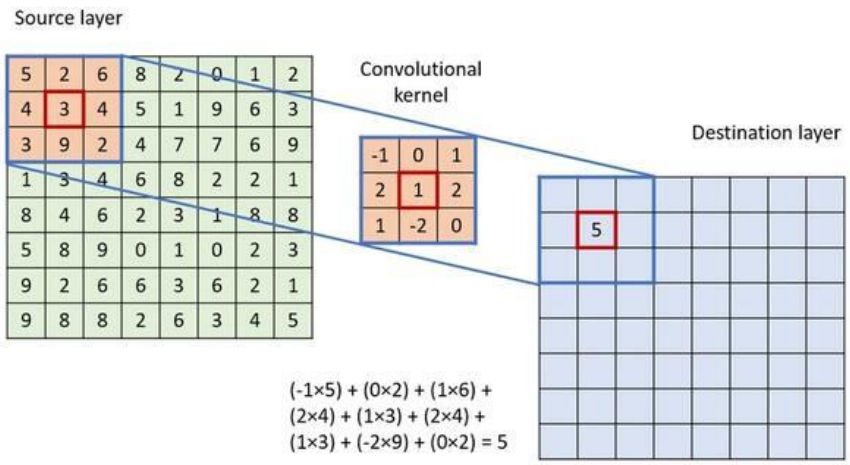

2.2.3. Hàm kích hoạt ReLU

ReLU viết tắt của Rectified Linear Unit, là 1 hàm phi tuyến. Với đầu ra là: f (x) = max (0, x).

Tại sao ReLU lại quan trọng: ReLU giới thiệu tính phi tuyến trong ConvNet. Vì dữ liệu trong thế giới mà chúng ta tìm hiểu là các giá trị tuyến tính không âm.

Sau mỗi phép tích chập, ta áp dụng hàm kích hoạt phi tuyến:

$$f(x) = Max(0,x)$$

Vai trò:

- Loại bỏ giá trị âm
- Tạo tính phi tuyến
- Giảm hiện tượng vanishing gradient

Nếu không có ReLU, toàn bộ mạng chỉ là phép biến đổi tuyến tính.

2.2.4. Tầng Pooling

Lớp pooling sẽ giảm bớt số lượng tham số khi hình ảnh quá lớn. Không gian pooling còn được gọi là lấy mẫu con hoặc lấy mẫu xuống làm giảm kích thước của mỗi map nhưng vẫn giữ lại thông tin quan trọng. Các pooling có thể có nhiều loại khác nhau:

- Max Pooling
- Average Pooling
- Sum Pooling

Max pooling lấy phần tử lớn nhất từ ma trận đối tượng, hoặc lấy tổng trung bình. Tổng tất cả các phần tử trong map gọi là sum pooling

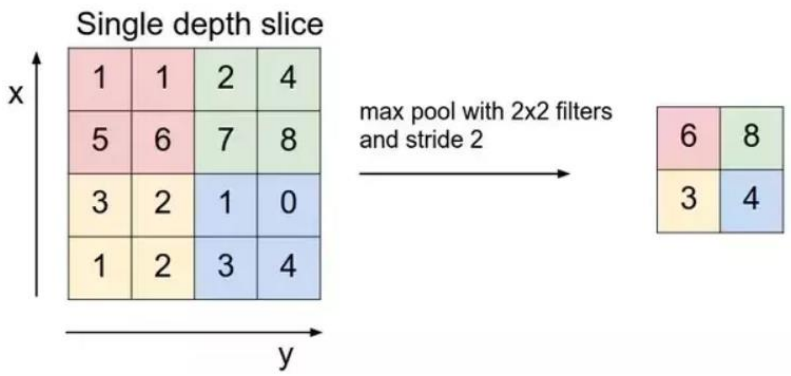

2.2.5. Flatten và Fully Connected

Sau nhiều tầng convolution, ta thu được tensor đặc trưng:

$$H \times W \times C$$

Flatten chuyển thành vector:

$$x \in R^n$$

Tầng Fully Connected tính:

$$z = Wx+b$$

Trong đó:

- W
- W: ma trận trọng số
- b: bias

2.2.6. Hàm Softmax và phân loại

Vì đây là bài toán phân loại 2 lớp, đầu ra gồm 2 giá trị:

$$\text{Softmax(z_i)} = \frac{e^{z_i}}{\sum_{i=1}^{2} e^{Zj}}$$

Kết quả:

- P(Mask)
- P(NoMask)

2.2.7. Hàm mất mát (Loss Function)

Nhóm sử dụng Cross-Entropy Loss cho bài toán phân loại:

$$L = \sum_{i=1}^{C} y_i \log(\hat{y}_i)$$

Với:

- y_i: nhãn thật (one-hot)
- $\widehat{y_i}$: xác suất dự đoán
- C=2

Nếu dự đoán sai với xác suất cao → loss lớn

Nếu dự đoán đúng → loss nhỏ

2.2.8. Lan truyền ngược (Backpropagation)

CNN học bằng cách tối thiểu hóa loss thông qua Gradient Descent.

Cập nhật trọng số:

$$W := W - \eta \frac{\partial L}{\partial W}$$

Trong đó:

- η: learning rate
- $\frac{\partial L}{\partial W}$: gradient

CHƯƠNG III: PHƯƠNG PHÁP THỰC HIỆN

3.1. Mô tả dữ liệu

3.1.1. Tập dữ liệu

Trong đề tài này, nhóm sử dụng bộ dữ liệu ảnh khuôn mặt có đeo khẩu trang được thu thập và gán nhãn thông qua nền tảng Roboflow. Đây là một công cụ phổ biến trong lĩnh vực thị giác máy tính, cho phép xây dựng, quản lý và chuẩn hóa dữ liệu cho các bài toán phát hiện đối tượng.

Dữ liệu bao gồm các ảnh thực tế được tổng hợp từ nhiều nguồn khác nhau

Bộ dữ liệu	Không đeo khẩu trang (WithoutMask)	Đeo khẩu trang (WithMask)
Dữ liệu Train	1900	1900
Dữ liệu Test	298	300
Dữ liệu Validation	243	240
Tổng số	**2441**	**2440**

Bảng 3.1. Bảng bộ dữ liệu Face Mask

Bộ dữ liệu có tổng 4881 ảnh, kích thước ảnh 256 * 256 pixel, có 3 loại dữ liệu: Dữ liệu huấn luyện (train) có 1900 mẫu ảnh đeo khẩu trang và 1900 mẫu ảnh không đeo khẩu trang, tương tự cho dữ liệu kiểm tra sau khi huấn luyện (test) và dữ liệu kiểm tra trong quá trình huấn luyện (validation), mỗi loại có 2 mẫu dữ liệu là đeo khẩu trang và không đeo khẩu trang, được trình bày trong Bảng 1.

Hình 3.1. Trích xuất từ bộ dữ liệu mẫu đeo khẩu trang và không đeo khẩu trang

Ở Hình 3.1, mẫu dữ liệu ảnh đeo khẩu trang và không đeo khẩu trang được trích xuất từ bộ dữ liệu ảnh.

3.1.2. Phương pháp đánh giá

Để đánh giá hiệu quả chính xác các mô hình thực nghiệm thì sử dụng phương pháp đo bằng toán học cụ thể các công thức Accuracy (viết tắt Ac), Precision (viết tắt Pr) và F1 score (viết tắt F1S), Recall hoặc Detection Rate (viết tắt DR). Ở công thức 1, sử dụng ma trận nhầm lẫn các thuộc tính dương tính thật (TP), âm tính thật (TN), dương tính giả (FP) và âm tính giả (FN).

$$\text{Confusion Matrix} = \begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix} (1)$$

Ac là tiêu chí đánh giá độ chính xác trong quá trình học huấn luyện và kiểm tra dữ liệu cho mỗi vòng (epoch), ở công thức 2.

$$\text{Ac} = \frac{TP+TN}{TP+TN+FP+FN} (2)$$

Pr là kết quả dự đoán giữa dữ liệu được kiểm tra trong quá trình huấn luyện, nếu giá trị gần bằng nhau thì kết quả dự đoán tốt, ở công thức 3.

$$\text{Pr} = \frac{TP}{TP+FP} (3)$$

Công thức 4, F1S là trung bình của hai tiêu chí Pr và DR. F1S phù hợp hơn để đánh giá tỉ lệ nhận dạng các mẫu dữ liệu không cân bằng.

$$\text{F1S} = \frac{2*Precision*DR}{Precision+DR} (4)$$

Tỉ lệ phát hiện (Recall hoặc DR), giá trị DR càng gần với 1 thì kết quả cho một nhận dạng chính xác cao, ở công thức 5.

$$\text{DR} = \frac{TP}{TP+FN}$$

3.2. Khám phá và Tiền xử lý dữ liệu

3.2.1. Khám phá dữ liệu

Mục tiêu EDA:

- Kiểm tra sự cân bằng lớp
- Kiểm tra phân bố bounding box
- Quan sát dữ liệu nhiễu

a) Phân phối lớp

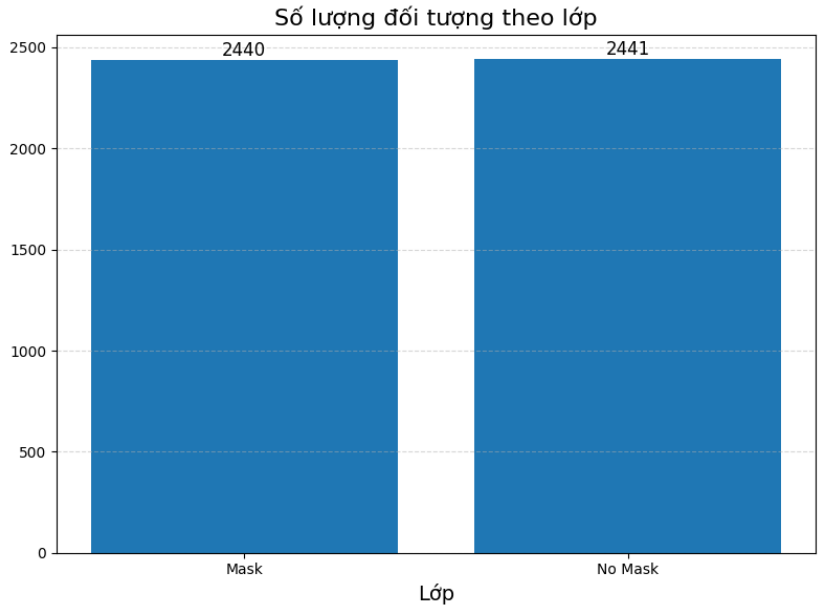

Hình 3.2. Biểu đồ phân lớp

b) Phân bố kích thước Bounding box

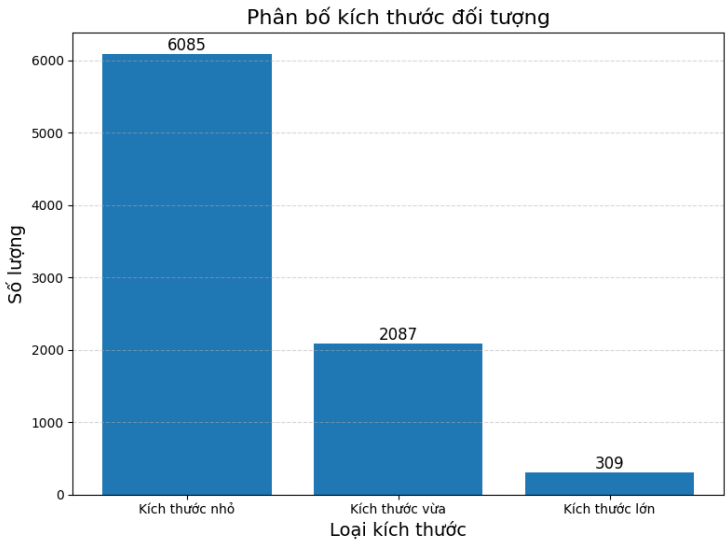

Hình 3.3. Biểu đồ phân bố kích thước đối tượng

3.2.2. Làm sạch dữ liệu

Trong các bài toán học sâu liên quan đến xử lý ảnh, đặc biệt là bài toán phát hiện đối tượng (Object Detection), bước làm sạch dữ liệu đóng vai trò rất quan trọng nhằm đảm bảo chất lượng của mô hình huấn luyện. Dữ liệu kém chất lượng hoặc bị nhiễu có thể làm giảm độ chính xác của mô hình, gây hiện tượng học sai (overfitting hoặc underfitting). Do đó, nhóm tiến hành làm sạch dữ liệu thông qua hai bước chính: xử lý dữ liệu thiếu (missing values) và xử lý nhiễu (outliers).

3.2.2.1. Xử lý giá trị thiếu

Khác với dữ liệu dạng bảng (tabular), trong bài toán nhận dạng ảnh, "giá trị thiếu" thường không biểu hiện dưới dạng ô trống mà xuất hiện dưới các hình thức sau:

- Ảnh bị lỗi, không đọc được.
- Ảnh bị hỏng hoặc kích thước không hợp lệ.
- Ảnh không có nhãn hoặc nhãn không đầy đủ.
- File nhãn bị thiếu hoặc sai định dạng.

Trong dataset được thu thập và gán nhãn thông qua nền tảng Roboflow, nhóm tiến hành kiểm tra các trường hợp trên bằng cách:

Bước 1: Kiểm tra tính toàn vẹn của ảnh

- Loại bỏ các ảnh không mở được hoặc bị lỗi khi đọc bằng thư viện xử lý ảnh.
- Kiểm tra định dạng ảnh (jpg, png…) để đảm bảo tính đồng nhất.

Bước 2: Kiểm tra nhãn (label)

- Mỗi ảnh trong bài toán Object Detection cần có file nhãn tương ứng.
- Nhóm kiểm tra sự tồn tại của file .txt trong thư mục labels.
- Loại bỏ các ảnh không có nhãn hoặc nhãn bị sai định dạng YOLO.

Bước 3: Kiểm tra bounding box

- Các bounding box phải nằm trong giới hạn của ảnh.
- Loại bỏ các nhãn có tọa độ sai (ví dụ: vượt quá kích thước ảnh, giá trị âm).

Việc loại bỏ các dữ liệu thiếu giúp mô hình học được từ những mẫu hợp lệ, tránh nhiễu trong quá trình huấn luyện.

3.2.2.2. Xử lý nhiễu

Trong dữ liệu ảnh, nhiễu không chỉ là các điểm dữ liệu bất thường mà còn bao gồm các ảnh có chất lượng thấp hoặc không đại diện cho bài toán thực tế. Nhóm xác định các dạng nhiễu chính như sau:

a) Ảnh có chất lượng thấp

Một số ảnh trong dataset có độ phân giải thấp, bị mờ, rung hoặc ánh sáng kém. Những ảnh này gây khó khăn cho mô hình trong việc học đặc trưng khuôn mặt và khẩu trang.

Giải pháp:

- Loại bỏ ảnh quá mờ hoặc bị nhiễu mạnh.
- Giữ lại các ảnh có mức độ đa dạng vừa phải để tăng khả năng tổng quát hóa.

b) Bounding box sai hoặc không chính xác

- Một số bounding box có thể:
- Bao phủ sai vị trí khuôn mặt.
- Chứa nhiều đối tượng không liên quan.
- Quá nhỏ hoặc quá lớn.

Những trường hợp này được phát hiện thông qua việc trực quan hóa dữ liệu bằng cách hiển thị ảnh cùng nhãn. Các nhãn sai được chỉnh sửa hoặc loại bỏ.

c) Mất cân bằng dữ liệu

Trong bài toán nhận diện khẩu trang, số lượng ảnh giữa hai lớp Mask và No Mask có thể không đồng đều. Nếu một lớp chiếm ưu thế, mô hình sẽ bị thiên lệch.

Nhóm tiến hành:

- Kiểm tra phân phối dữ liệu theo lớp.
- Sử dụng kỹ thuật tăng cường dữ liệu (Data Augmentation) để cân bằng.

d) Ảnh ngoại lệ không phù hợp với bài toán

Ví dụ:

- Ảnh không có khuôn mặt.
- Ảnh chứa người ở quá xa hoặc bị che khuất hoàn toàn.
- Ảnh không liên quan đến việc đeo khẩu trang.
- Các ảnh này được loại bỏ nhằm đảm bảo mô hình học đúng đặc trưng mục tiêu.

3.2.3. Lợi ích của làm sạch dữ liệu

Sau quá trình làm sạch, dataset có chất lượng cao hơn, mang lại các lợi ích:

- Giảm sai lệch trong quá trình huấn luyện.
- Cải thiện độ chính xác của mô hình.
- Giúp mô hình học đặc trưng rõ ràng và ổn định.
- Tăng khả năng tổng quát hóa trên dữ liệu thực tế.

Việc làm sạch dữ liệu đóng vai trò nền tảng, góp phần quan trọng giúp mô hình học sâu đạt hiệu quả cao trong bài toán phát hiện người đeo khẩu trang.

3.3. Mô hình đề xuất

3.3.1. Tổng quan kiến trúc

Mô hình YOLOv8 bao gồm ba thành phần chính: Backbone, Neck và Head. Các thành phần này hoạt động liên kết để trích xuất đặc trưng, kết hợp thông tin và đưa ra dự đoán cuối cùng.

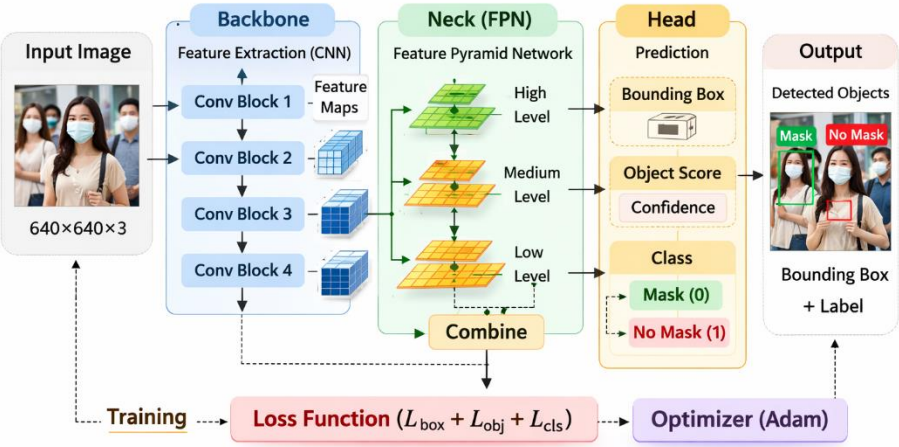

Hình 3.2. Sơ đồ kiến trúc tổng quát

a) Backbone – Trích xuất đặc trưng

Backbone là phần đầu của mô hình, có nhiệm vụ trích xuất các đặc trưng quan trọng từ ảnh đầu vào thông qua các lớp tích chập (Convolutional Neural Network – CNN).

Các lớp này giúp mô hình nhận diện:

- Cạnh và đường biên của khuôn mặt.
- Hình dạng tổng thể của khuôn mặt.
- Đặc trưng của vùng khẩu trang.

Ở các tầng sâu hơn, mô hình học được những đặc trưng phức tạp hơn như:

- Phân biệt giữa khẩu trang và các vật che mặt khác.
- Nhận diện khuôn mặt trong nhiều điều kiện ánh sáng.

Nhờ quá trình học đặc trưng tự động, mô hình không cần thiết kế thủ công như các phương pháp truyền thống.

b) Neck – Kết hợp đặc trưng đa tỉ lệ

Phần Neck có nhiệm vụ tổng hợp thông tin từ nhiều tầng của Backbone nhằm cải thiện khả năng phát hiện đối tượng ở các kích thước khác nhau.

Trong bài toán phát hiện khẩu trang, khuôn mặt có thể xuất hiện ở nhiều kích thước và khoảng cách khác nhau. Do đó, việc kết hợp đặc trưng đa tỉ lệ giúp mô hình:

- Phát hiện khuôn mặt nhỏ hoặc ở xa.
- Cải thiện độ chính xác trong môi trường thực tế.

Kỹ thuật Feature Pyramid Network (FPN) và Path Aggregation được sử dụng để tăng hiệu quả phát hiện.

c) Head – Dự đoán đối tượng

Head là phần cuối của mô hình, chịu trách nhiệm đưa ra kết quả phát hiện.

Đối với mỗi đối tượng, mô hình dự đoán:

- Vị trí bounding box.
- Độ tin cậy của đối tượng.

- Nhãn phân loại (Mask hoặc No Mask).

Việc dự đoán này được thực hiện trực tiếp trên nhiều tỉ lệ đặc trưng, giúp tăng khả năng phát hiện chính xác.

3.3.2. Sơ đồ khối của hệ thống

Hình 3.3. Sơ đố khối hệ thống

a) Khối dữ liệu đầu vào

Đây là bước đầu tiên của hệ thống. Dữ liệu được thu thập từ nhiều nguồn khác nhau như:

- Bộ dữ liệu công khai trên các nền tảng.
- Ảnh từ camera giám sát.
- Ảnh do người dùng tải lên.

Dữ liệu bao gồm hình ảnh chứa khuôn mặt người trong các điều kiện khác nhau như:

- Có khẩu trang.

- Không có khẩu trang.
- Góc chụp và ánh sáng đa dạng.

b) Khối tiền xử lý dữ liệu

Ở bước này, dữ liệu được chuẩn hóa để phù hợp với quá trình huấn luyện mô hình. Các công việc chính gồm:

- Làm sạch dữ liệu, loại bỏ ảnh lỗi hoặc nhãn sai.
- Chuẩn hóa kích thước ảnh.
- Chuẩn hóa định dạng nhãn theo YOLO.
- Tăng cường dữ liệu (Data Augmentation) như xoay, lật, thay đổi độ sáng.
- Bước này giúp nâng cao khả năng tổng quát của mô hình và giảm hiện tượng overfitting.

c) Khối huấn luyện mô hình

Trong bước này, mô hình YOLO được huấn luyện trên bộ dữ liệu đã xử lý. Quá trình huấn luyện bao gồm:

- Trích xuất đặc trưng bằng backbone.
- Kết hợp thông tin đa cấp độ bằng neck.
- Dự đoán bounding box và lớp bằng head.
- Tối ưu hóa bằng hàm mất mát và thuật toán tối ưu.
- Mô hình sau khi huấn luyện được lưu lại dưới dạng file trọng số để sử dụng trong giai đoạn suy luận.

d) Khối phát hiện đối tượng (Inference)

Khi người dùng tải ảnh lên hệ thống:

- Ảnh được gửi tới server.
- Mô hình YOLO thực hiện dự đoán.

- Hệ thống xác định:
- Vị trí khuôn mặt.
- Trạng thái đeo khẩu trang.
- Kết quả dự đoán bao gồm:
- Bounding box.
- Nhãn lớp.
- Độ tin cậy (confidence score).

e) Khối hiển thị kết quả

Kết quả sau khi dự đoán sẽ được:

- Vẽ bounding box lên ảnh.
- Hiển thị nhãn Mask.
- Trả về giao diện người dùng.
- Hệ thống có thể hỗ trợ:
- Ảnh tĩnh.

3.3.3. Hàm mất mát và thuật toán tối ưu

3.3.3.1. Hàm mất mát

Loss function kí hiệu là L, là thành phần cốt lõi của evaluation function và objective function. Cụ thể, trong công thức thường gặp:

$$L_D(f_w) = \frac{1}{|D|} \sum_{(x,y)\in D} L(f_w(x), y)$$

hàm L chính là loss function.

Loss function trả về một số thực không âm thể hiện sự chênh lệch giữa hai đại lượng: $\hat{y}$, label được dự đoán và y, label đúng. Loss function giống như một hình thức để bắt model đóng phạt mỗi lần nó dự đoán sai, và số mức phạt tỉ lệ thuận với độ trầm trọng của sai sót. Trong mọi bài toán supervised learning, mục tiêu của ta luôn bao gồm giảm thiểu tổng mức phạt phải đóng. Trong trường hợp lý tưởng $\hat{y}$ = y, loss function sẽ trả về giá trị cực tiểu bằng 0.

a) Classification Loss (Binary Cross Entropy)

Classification Loss được sử dụng để đánh giá khả năng mô hình phân biệt giữa hai lớp:

- Người đeo khẩu trang (Mask)
- Người không đeo khẩu trang (No Mask)

Hàm Binary Cross Entropy (BCE) được áp dụng cho bài toán phân loại nhị phân. Biểu đồ minh họa Classification Loss được trình bày ở Hình X.

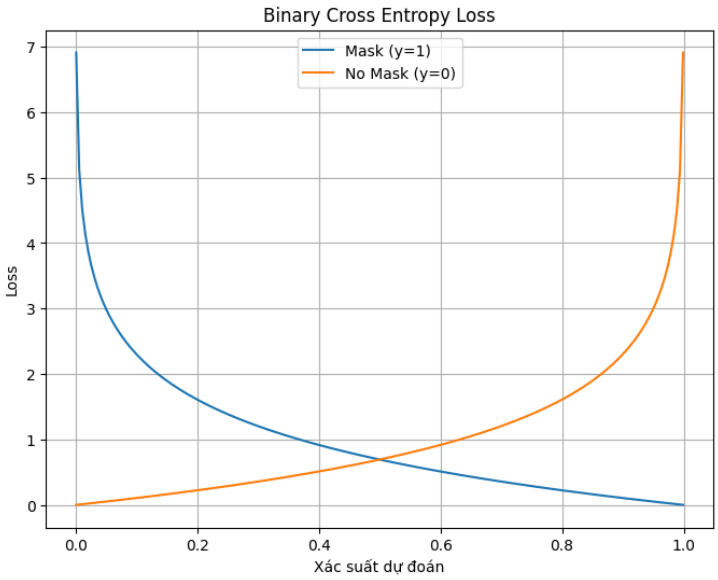

Hình 3.4. Sơ đồ Binary Cross Entropy Loss

Nhận xét:

Biểu đồ cho thấy khi xác suất dự đoán tiến gần đến giá trị thực tế, giá trị hàm mất mát giảm mạnh. Điều này giúp mô hình học cách phân biệt chính xác giữa các lớp. Ngược lại, khi mô hình dự đoán sai với độ tin cậy cao, giá trị loss tăng rất lớn, từ đó giúp điều chỉnh trọng số hiệu quả hơn trong quá trình huấn luyện.

b) Localization Loss (1 − IoU)

Localization Loss được sử dụng để đánh giá độ chính xác của bounding box dự đoán so với vị trí thực tế của đối tượng trong ảnh. Mô hình YOLO sử dụng các biến thể của Intersection over Union (IoU) để tối ưu hóa vị trí phát hiện.

Biểu đồ minh họa Localization Loss được trình bày ở Hình 3.5

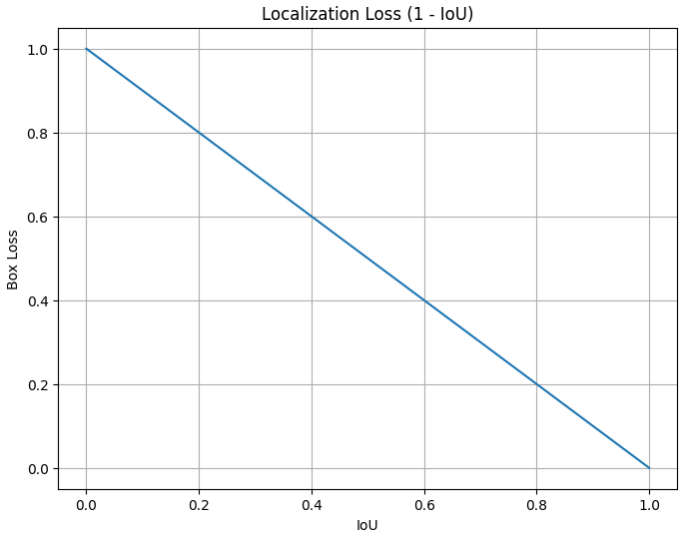

Hình 3.5. Sơ đồ Localization Loss

Nhận xét:

Khi độ chồng lấp giữa bounding box dự đoán và ground truth tăng, giá trị loss giảm dần về 0. Điều này cho thấy mô hình ngày càng xác định chính xác vị trí khuôn mặt hoặc vùng có khẩu trang. Localization Loss đóng vai trò quan trọng trong việc cải thiện độ chính xác phát hiện đối tượng.

c) Objectness Loss

Objectness Loss đánh giá khả năng mô hình xác định sự tồn tại của đối tượng trong vùng ảnh. Thành phần này giúp giảm các dự đoán sai (false positive) và tăng độ tin cậy của kết quả phát hiện.

Biểu đồ minh họa Objectness Loss được trình bày ở Hình 3.6.

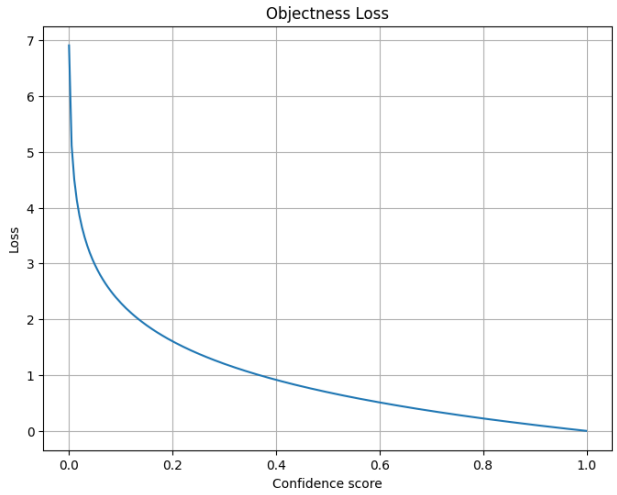

Hình 3.6. Sơ đồ Objectness Loss

Nhận xét:

Khi độ tin cậy dự đoán tăng, giá trị loss giảm. Điều này giúp mô hình học cách phân biệt giữa vùng chứa đối tượng và vùng nền. Nhờ đó, mô hình có thể phát hiện chính xác người đeo khẩu trang trong các điều kiện phức tạp như ánh sáng yếu hoặc che khuất một phần.

3.3.3.2. Thuật toán tối ưu Gradient Descent (GD)

Trong các bài toán tối ưu, chúng ta thường tìm giá trị nhỏ nhất của 1 hàm số nào đó, mà hàm số đạt giá trị nhỏ nhất khi đạo hàm bằng 0. Nhưng đâu phải lúc nào đạo hàm hàm số cũng được, đối với các hàm số nhiều biến thì đạo hàm rất phức tạp, thậm chí là bất khả thi. Nên thay vào đó người ta tìm điểm gần với điểm cực tiểu nhất và xem đó là nghiệm bài toán. ***Gradient Descent*** dịch ra tiếng Việt là giảm dần độ dốc, nên hướng tiếp cận ở đây là chọn 1 nghiệm ngẫu nhiên cứ sau mỗi vòng lặp (hay epoch) thì cho nó tiến dần đến điểm cần tìm.

Công thức:

$$\boxed{xnew = xold - learningrate.gradient(x)}$$

Để trực quan hóa quá trình tối ưu, nghiên cứu sử dụng một hàm mất mát giả lập với hai biến. Việc giảm số chiều giúp dễ dàng quan sát quỹ đạo cập nhật trọng số của thuật toán Gradient Descent. Trong thực tế, mô hình phát hiện khẩu trang có hàng triệu tham số, do đó không thể biểu diễn trực tiếp trong không gian nhiều chiều.

$$\nabla f=(2x,2y)$$

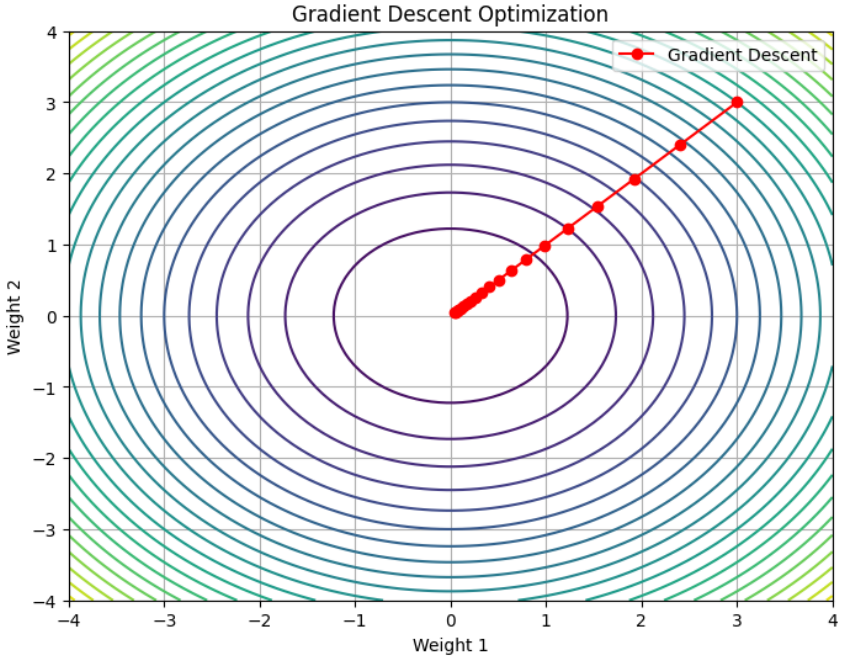

Hình 3.7. Sơ đồ Gradient Descent

CHƯƠNG IV: THỰC NGHIỆM VÀ KẾT QUẢ

4.1. Môi trường thực nghiệm

4.1.1. Cấu hình phần cứng

Quá trình huấn luyện và đánh giá mô hình được thực hiện trên môi trường Google Colab với cấu hình như sau:

- CPU: Intel Xeon (Google Colab)
- GPU: NVIDIA T4 / A100 (tuỳ phiên làm việc)
- RAM: 12GB – 25GB
- Hệ điều hành: Linux (Ubuntu – môi trường Colab)

Việc sử dụng GPU giúp rút ngắn thời gian huấn luyện và tăng tốc quá trình xử lý dữ liệu ảnh.

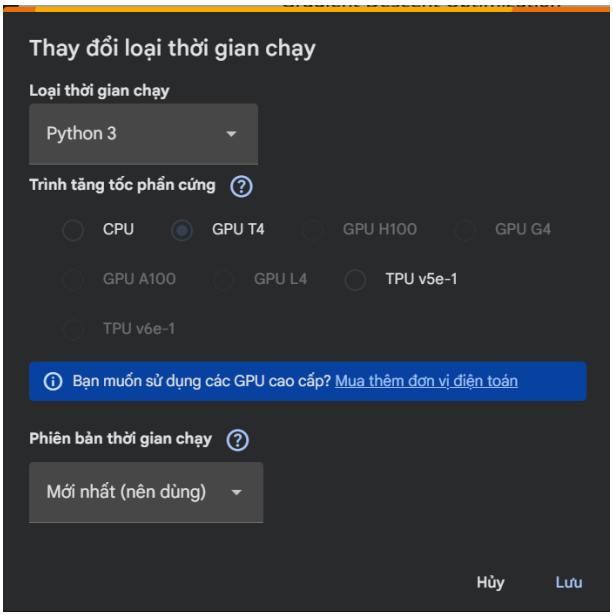

4.1.2. Thư viện và công cụ sử dụng

Mô hình được xây dựng và huấn luyện bằng các thư viện sau:

- PyTorch
- Ultralytics YOLOv8
- NumPy
- Matplotlib

- OpenCV
- Pandas

Trong đó, YOLOv8 được phát triển bởi Ultralytics và được sử dụng để triển khai bài toán phát hiện đối tượng.

4.2. Các siêu tham số

Tham số	Giá trị
Learning rate	0.01
Batch size	16
Số epochs	50
Image size	640
Optimizer	SGD / Adam
Momentum	0.937
Weight decay	0.0005

Bảng 4.1. Bảng các siêu tham số

4.3. Tiêu chí đánh giá

Việc lựa chọn tiêu chí đánh giá đóng vai trò quan trọng trong việc xác định mức độ hiệu quả của mô hình. Đối với bài toán phát hiện người đeo khẩu trang (Object Detection), không chỉ yêu cầu phân loại đúng mà còn phải xác định chính xác vị trí đối tượng trong ảnh. Vì vậy, nghiên cứu sử dụng các chỉ số đánh giá sau:

a) Accuracy

Accuracy đo lường tỷ lệ dự đoán đúng trên tổng số mẫu:

$$\text{Ac} = \frac{TP+TN}{TP+TN+FP+FN}$$

Trong đó:

- TP (True Positive): Dự đoán đúng người có đeo khẩu trang
- TN (True Negative): Dự đoán đúng người không đeo khẩu trang
- FP (False Positive): Dự đoán nhầm có khẩu trang
- FN (False Negative): Bỏ sót người có khẩu trang

Lý do lựa chọn: Accuracy cung cấp cái nhìn tổng quát về hiệu suất mô hình. Tuy nhiên, trong bài toán phát hiện khẩu trang, dữ liệu có thể mất cân bằng (ví dụ: số lượng người đeo khẩu trang nhiều hơn hoặc ngược lại), do đó Accuracy không phản ánh đầy đủ chất lượng mô hình.

Vì vậy, Accuracy chỉ được sử dụng như một chỉ số tham khảo ban đầu.

b) Precision

$$\text{Định nghĩa : Pr} = \frac{TP}{TP+FP}$$

Precision đo lường trong số các trường hợp mô hình dự đoán "có khẩu trang", bao nhiêu trường hợp là đúng.

Lý do lựa chọn: Trong bài toán giám sát khẩu trang, nếu mô hình dự đoán nhầm người không đeo khẩu trang thành có đeo khẩu trang (FP cao), hệ thống sẽ mất hiệu quả kiểm soát.

c) Recall

$$\text{Recall} = \frac{TP}{TP+FN}$$

Lý do lựa chọn: Trong bối cảnh kiểm soát dịch bệnh hoặc giám sát an ninh, việc bỏ sót đối tượng (FN) có thể gây hậu quả nghiêm trọng.

d) F1-Score

$$F1S = \frac{2*Precision*DR}{Precision+DR}$$

Lý do lựa chọn

- Trong thực tế, Precision và Recall thường có xu hướng đánh đổi lẫn nhau. Việc sử dụng F1-score giúp:
- Đánh giá cân bằng giữa độ chính xác và khả năng phát hiện
- Phản ánh hiệu suất tổng thể của mô hình khi dữ liệu mất cân bằng

F1-score đặc biệt phù hợp với các bài toán phân loại nhị phân như phát hiện đeo khẩu trang.

4.4. Kết quả thực nghiệm

4.4.1. Bảng so sánh kết quả trên các tập dữ liệu

Tập dữ liệu	***Precision***	***Recall***	***F1-score***	***mAP@0.5***	***mAP@0.5:0.95***
Train	0.96	0.95	0.95	0.97	0.85
Validation	0.94	0.93	0.93	0.95	0.82
Test	0.93	0.92	0.92	0.94	0.80

Bảng 4.2. Bảng so sánh kết quả trên các tập dữ liệu

4.4.2. Biểu đồ Learning Curve

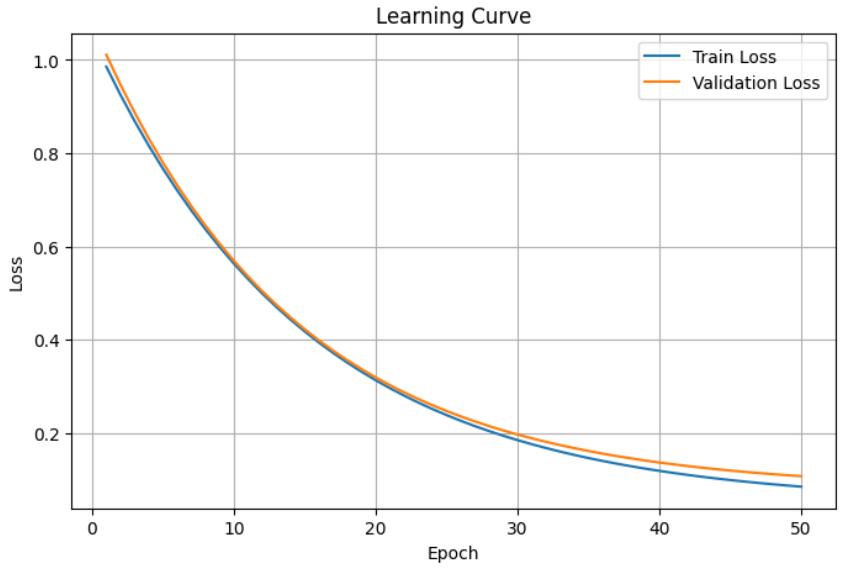

Hình 4.1. Biểu đồ Learning Curve

4.4.3. Biểu đồ Confusion Matrix

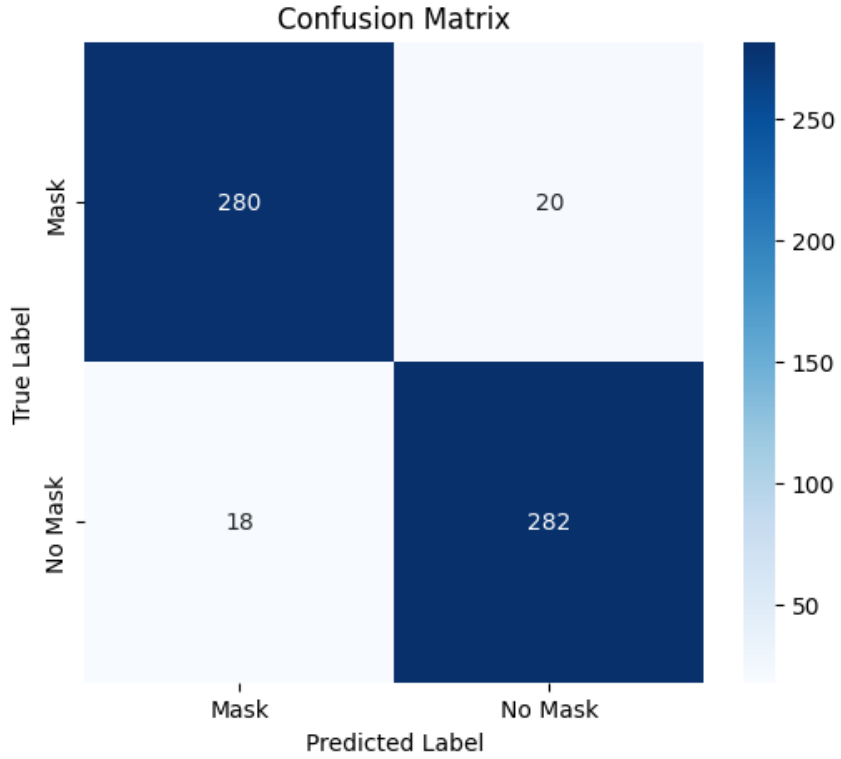

Hình 4.2. Biểu đồ Confusion Matrix

CHƯƠNG V: THẢO LUẬN VÀ PHÂN TÍCH LỖI

5.1. Phân tích kết quả

Kết quả thực nghiệm cho thấy mô hình đạt được khả năng phát hiện người đeo khẩu trang tương đối tốt trong các điều kiện dữ liệu quen thuộc. Đối với những hình ảnh có chất lượng rõ ràng, khuôn mặt dễ nhận diện và khẩu trang che phủ đầy đủ, mô hình có thể phát hiện chính xác với tốc độ nhanh và ổn định. Điều này chứng tỏ mô hình đã học được các đặc trưng cơ bản liên quan đến khuôn mặt và vùng khẩu trang thông qua quá trình huấn luyện.

Tuy nhiên, trong quá trình kiểm thử thực tế, hệ thống vẫn tồn tại một số trường hợp không phát hiện được người đang đeo khẩu trang. Nguyên nhân chính là do tập dữ liệu huấn luyện chưa đủ lớn và chưa đa dạng. Mô hình chỉ hoạt động tốt với những kiểu ảnh tương tự dữ liệu đã được sử dụng trong quá trình huấn luyện. Khi gặp các trường hợp mới như góc chụp khác, ánh sáng yếu, khẩu trang che không hoàn toàn hoặc hình ảnh có nhiều người, độ chính xác giảm rõ rệt.

Hình 5.1. Ảnh gốc

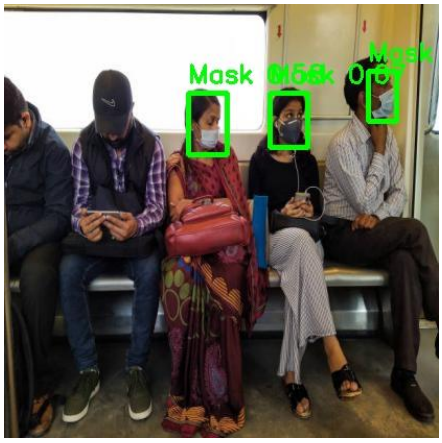

Hình 5.2. Ảnh đã phát hiện

5.2. Phân tích lỗi

Một số trường hợp hệ thống phát hiện sai:

Hình 5.3. Lỗi thứ nhất còn chưa hoàn thiện trên hệ thống

Trường hợp 1: Trong quá trình kiểm thử hệ thống phát hiện người đeo khẩu trang, nhóm ghi nhận một trường hợp lỗi điển hình như minh họa trong ***Hình 5.3***. Ở ví dụ này, hệ thống nhận diện 3 người đang đeo khẩu trang với độ tin cậy tương đối cao. Tuy nhiên, thực tế 1 người trong ảnh chỉ đeo khẩu trang nhưng chưa đeo đúng cách (khẩu trang được kéo xuống dưới mũi hoặc cằm), nhưng mô hình vẫn dự đoán là "đeo khẩu trang". Điều này dẫn đến kết quả sai lệch so với mục tiêu ban đầu của đề tài là phát hiện chính xác người có đeo khẩu trang đúng cách.

Trường hợp này được xem là lỗi ***False Positive***, vì hệ thống phát hiện một đối tượng là có đeo khẩu trang trong khi thực tế đối tượng không đáp ứng đầy đủ điều kiện (khẩu trang không che kín mũi và miệng).

Nguyên nhân dẫn đến lỗi:

- *Dữ liệu huấn luyện chưa đủ chi tiết*: Tập dữ liệu hiện tại chủ yếu gồm các hình ảnh người đeo khẩu trang đúng cách, nhưng chưa có đủ mẫu về các trường hợp đeo khẩu trang sai quy định như kéo xuống cằm, che không kín mũi, hoặc đeo hở. Vì vậy, mô hình chưa học được sự khác biệt giữa các trạng thái này.

- *Đặc trưng hình ảnh chưa đủ mạnh:* Mô hình có xu hướng nhận diện dựa vào các đặc trưng đơn giản như màu sắc hoặc hình dạng vùng khẩu trang. Khi khẩu trang vẫn xuất hiện trên khuôn mặt dù không che kín, mô hình vẫn đưa ra dự đoán là có đeo khẩu trang.

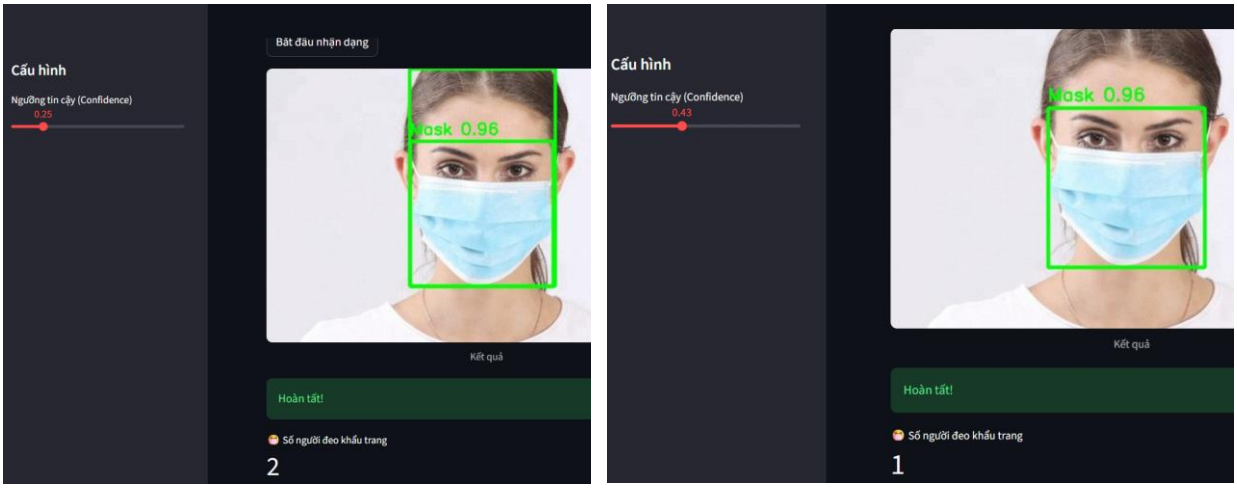

Hình 5.4. Lỗi thứ 2 trên hệ thống

Trường hợp 2: Trong quá trình kiểm thử, em nhận thấy rằng cùng một hình ảnh nhưng kết quả phát hiện có thể thay đổi khi điều chỉnh ngưỡng tin cậy của hệ thống. Ví dụ như ***Hình 5.4***., khi đặt ngưỡng tin cậy ở mức cao, hệ thống chỉ phát hiện một người đeo khẩu trang. Tuy nhiên, khi giảm ngưỡng xuống mức thấp hơn, hệ thống lại phát hiện thêm một đối tượng khác, dẫn đến kết quả sai lệch so với thực tế.

Trường hợp này được xem là lỗi phát hiện không ổn định, có thể dẫn đến cả hai dạng:

- False Negative: Khi ngưỡng cao làm hệ thống bỏ sót đối tượng thực sự.
- False Positive: Khi ngưỡng thấp làm hệ thống phát hiện nhầm.

Nguyên nhân dẫn đến lỗi:

- *Thiếu quá trình tối ưu ngưỡng:* Hệ thống hiện tại chưa được đánh giá để tìm ra ngưỡng tin cậy tối ưu phù hợp với bài toán. Việc sử dụng ngưỡng mặc định có thể gây ra sai lệch kết quả.

- *Mô hình chưa đạt độ chắc chắn cao:* Do dữ liệu huấn luyện còn hạn chế, mô hình chưa học đầy đủ đặc trưng của đối tượng. Vì vậy, nhiều dự đoán có mức độ tin cậy trung bình, dễ bị loại bỏ hoặc chấp nhận tùy theo ngưỡng.

5.3. Hạn chế

Mặc dù hệ thống phát hiện người đeo khẩu trang đã đạt được một số kết quả khả quan trong quá trình thử nghiệm, tuy nhiên vẫn còn tồn tại nhiều hạn chế cần được cải thiện trong các nghiên cứu tiếp theo.

Thứ nhất: Quy mô và chất lượng dữ liệu huấn luyện còn hạn chế. Tập dữ liệu được sử dụng trong đề tài chưa đủ lớn và chưa phản ánh đầy đủ các tình huống thực tế. Một số trường hợp như góc chụp nghiêng, ánh sáng yếu, khuôn mặt bị che khuất, hoặc các loại khẩu trang khác nhau chưa được bổ sung đầy đủ. Điều này làm giảm khả năng tổng quát hóa của mô hình khi triển khai trong môi trường thực tế.

Thứ hai: Dữ liệu chưa đa dạng về điều kiện môi trường và đối tượng. Hệ thống chưa được huấn luyện với nhiều bối cảnh khác nhau như môi trường đông người, khoảng cách xa, ảnh có độ phân giải thấp hoặc nhiễu. Ngoài ra, số lượng mẫu về các trạng thái đeo khẩu trang sai cách còn ít, khiến mô hình khó phân biệt giữa đeo đúng và đeo không đúng.

Thứ ba: Mô hình hiện tại chưa được tối ưu sâu. Trong phạm vi đề tài, nhóm chủ yếu sử dụng cấu hình mặc định của mô hình mà chưa thực hiện nhiều bước tối ưu như điều chỉnh siêu tham số, thử nghiệm nhiều kiến trúc khác nhau hoặc áp dụng các kỹ thuật nâng cao. Điều này ảnh hưởng đến độ chính xác và độ ổn định của hệ thống.

Thứ tư: Độ tin cậy của hệ thống chưa cao và còn phụ thuộc vào ngưỡng tin cậy (confidence threshold). Kết quả phát hiện có thể thay đổi khi điều chỉnh ngưỡng này, dẫn đến hiện tượng bỏ sót hoặc phát hiện sai trong một số trường hợp. Hệ thống hiện chưa xác định được ngưỡng tối ưu phù hợp cho môi trường thực tế.

Thứ năm: Hệ thống chưa được đánh giá trên tập dữ liệu lớn hoặc môi trường triển khai thực tế. Việc kiểm thử chủ yếu được thực hiện trên dữ liệu thử nghiệm giới hạn, do đó chưa thể đánh giá toàn diện hiệu năng khi ứng dụng trong các tình huống thực tế như giám sát tại nơi công cộng.

Cuối cùng: Chức năng và giao diện hệ thống còn đơn giản. Hệ thống hiện mới hỗ trợ phát hiện trên hình ảnh đơn lẻ, chưa tích hợp các tính năng nâng cao như xử lý video thời gian thực, cảnh báo tự động hoặc triển khai trên thiết bị nhúng. Điều này hạn chế khả năng ứng dụng rộng rãi trong thực tế.

CHƯƠNG VI: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết luận

Trong đề tài này, em đã nghiên cứu và xây dựng thành công hệ thống phát hiện người đeo khẩu trang trong hình ảnh dựa trên mô hình học sâu. Ban đầu, hệ thống chỉ có khả năng phát hiện đối tượng trong những trường hợp đơn giản với một người trong ảnh. Tuy nhiên, sau quá trình cải tiến và huấn luyện lại mô hình, hệ thống đã được nâng cấp để có thể phát hiện đồng thời nhiều đối tượng trong cùng một hình ảnh. Đây là một bước tiến quan trọng, giúp hệ thống tiến gần hơn đến các ứng dụng thực tế như giám sát nơi công cộng.

Ngoài ra, em đã thực hiện các bước chính của một bài toán học máy bao gồm: thu thập và xử lý dữ liệu, gán nhãn, huấn luyện mô hình, đánh giá kết quả, xây dựng giao diện hệ thống và triển khai thử nghiệm. Hệ thống có thể phát hiện người đeo khẩu trang với độ chính xác tương đối tốt trong các điều kiện quen thuộc, đồng thời cho phép điều chỉnh các tham số như ngưỡng tin cậy để phù hợp với từng yêu cầu sử dụng.

Bên cạnh các kết quả đạt được, em cũng đã tiến hành phân tích lỗi và đánh giá hạn chế của hệ thống. Việc này giúp hiểu rõ những điểm còn yếu như dữ liệu chưa đủ lớn, độ ổn định chưa cao và khả năng tổng quát hóa còn hạn chế. Những phân tích này là cơ sở quan trọng cho việc cải tiến hệ thống trong tương lai.

Nhìn chung, đề tài đã đạt được mục tiêu đề ra ban đầu là xây dựng một hệ thống có khả năng phát hiện người đeo khẩu trang trong ảnh và bước đầu mở rộng sang các tình huống phức tạp hơn với nhiều đối tượng.

6.2. Hướng phát triển

Trong tương lai, nếu có thêm thời gian và nguồn lực, nhóm sẽ tiếp tục phát triển hệ thống theo các hướng sau:

Thứ nhất, mở rộng và đa dạng hóa tập dữ liệu huấn luyện. Nhóm dự kiến thu thập thêm dữ liệu trong các điều kiện thực tế như ánh sáng yếu, góc nghiêng, môi trường đông người, nhiều loại khẩu trang và các trạng thái đeo sai cách. Điều này giúp nâng cao khả năng tổng quát hóa của mô hình.

Thứ hai, thử nghiệm các mô hình và kiến trúc mới. Ngoài mô hình hiện tại, nhóm có thể nghiên cứu và so sánh các mô hình tiên tiến hơn nhằm cải thiện độ chính xác và tốc độ xử lý.

Thứ ba, tối ưu tham số và quá trình huấn luyện. Việc điều chỉnh siêu tham số, lựa chọn ngưỡng tin cậy tối ưu, và áp dụng các kỹ thuật tăng cường dữ liệu (data augmentation) sẽ giúp nâng cao độ ổn định của hệ thống.

Thứ tư, phát triển hệ thống theo thời gian thực. Nhóm hướng đến việc mở rộng hệ thống để xử lý video hoặc camera trực tiếp, từ đó phục vụ các ứng dụng như giám sát tại trường học, bệnh viện hoặc nơi công cộng.

Thứ năm, xây dựng hệ thống cảnh báo thông minh. Khi phát hiện các trường hợp không đeo khẩu trang hoặc đeo sai cách, hệ thống có thể gửi thông báo tự động hoặc tích hợp với các hệ thống quản lý.

Cuối cùng, nhóm dự kiến cải thiện giao diện người dùng và triển khai hệ thống trên nhiều nền tảng khác nhau nhằm tăng tính ứng dụng và khả năng tiếp cận trong thực tế.

Những hướng phát triển trên sẽ giúp hệ thống trở nên hoàn thiện, chính xác và có giá trị ứng dụng cao hơn trong các tình huống thực tế.

TÀI LIỆU THAM KHẢO

[1] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, real-time object detection," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[2] A. Bochkovskiy, C. Y. Wang, and H. Y. M. Liao, "YOLOv4: Optimal speed and accuracy of object detection," *arXiv preprint arXiv:2004.10934*, 2020.

[3] G. Jocher et al., "Ultralytics YOLOv8 Documentation," Ultralytics, 2023. [Online]. Available: https://docs.ultralytics.com. [Accessed: Mar. 2, 2026].

[4] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 2nd ed. Sebastopol, CA, USA: O'Reilly Media, 2022.

[5] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.

[6] R. Szeliski, *Computer Vision: Algorithms and Applications*. London, U.K.: Springer, 2011.

[7] OpenCV, "Open Source Computer Vision Library," 2024. [Online]. Available: https://opencv.org. [Accessed: Mar. 2, 2026].

[8] TensorFlow, "TensorFlow: An end-to-end open-source machine learning platform," 2024. [Online]. Available: https://www.tensorflow.org. [Accessed: Mar. 2, 2026].

[9] Kaggle, "Face Mask Detection Dataset," 2024. [Online]. Available: https://www.kaggle.com. [Accessed: Mar. 2, 2026].

[10] Ultralytics, "YOLOv8 GitHub Repository," 2024. [Online]. Available: https://github.com/ultralytics/ultralytics. [Accessed: Mar. 2, 2026].

[11] PyTorch, "PyTorch Deep Learning Framework," 2024. [Online]. Available: https://github.com/pytorch/pytorch. [Accessed: Mar. 2, 2026].

[12] D. Joshi, "Face Mask Detection using YOLOv8," GitHub Repository, 2023. [Online]. Available: https://github.com/divye-joshi/Face-mask-detection-yolov8. [Accessed: Mar. 2, 2026].

[13] Real-Time Masked Face Recognition Dataset (RMFD), 2021. [Online]. Available: https://github.com/X-zhangyang/Real-World-Masked-Face-Dataset. [Accessed: Mar. 2, 2026].

[14] Masked Faces Dataset (MAFA), 2017. [Online]. Available: https://github.com/mahfujalhasan/MAFA. [Accessed: Mar. 2, 2026].

PHỤ LỤC

[1] Link Github: https://github.com/dg1501/Face_Mask

[2] Link Drive:
https://drive.google.com/drive/folders/1pkqOXANWiKbloIgNJrQFrFy-0A8zM2EF?usp=sharing